

Harga dan untung

Angka paketnya diambil dari `packages/db/src/plans.ts`. Kalau di sana berubah, perbarui berkas ini.

Paket

	Gratis	Starter	Growth	Pro
Harga per bulan	Rp 0	Rp 199.000	Rp 499.000	Rp 999.000
Balasan per bulan	51	3.000	15.000	30.000
Harga per balasan	—	Rp 66	Rp 33	Rp 33
Nomor WhatsApp	1	1	3	10
Asisten	1	1	5	20
Catatan info bisnis	10	20	200	1.000

Satu **balasan** berarti satu kali asisten menjawab, bukan satu baris pesan. Jawaban yang dipecah jadi tiga bubble tetap dihitung satu.

Yang dikunci per paket

Cuma dua, dan ditegakkan di worker bukan cuma disembunyikan di layar:

- **Baca foto dan pesan suara** — mulai Starter
- **Kirim foto, video, PDF dari galeri** — mulai Starter
- **Sapa duluan dan jam kerja tim** — mulai Growth

Semua sisanya, termasuk CRM, janji temu, dan ringkasan AI, **didapat paket gratis juga**. Itu keputusan sadar: yang bikin orang merasa Palwise mengerti usahanya justru fitur-fitur itu, dan menguncinya sebelum ada yang percaya sama sekali berarti memotong jalan sendiri.

Yang belum kamu tahu, dan ini yang paling penting

Dengan model yang sekarang, semua paket berbayar RUGI. Modelnya harus diganti, bukan harganya dinaikkan.

Dua hal yang harus dipisah, dan keduanya sekarang sudah ada angkanya: berapa token yang dipakai tiap balasan (diukur `npm run ukur:prompt`), dan berapa harga per token (dari halaman harga resmi Google). Rinciannya di bawah, beserta apa yang harus dikerjakan.

Worker juga mencatat token masuk dan keluar tiap balasan ke catatan prosesnya, jadi sesudah ada beberapa pelanggan sungguhan, angka rata-rata yang sebenarnya akan datang sendiri dan menggantikan perkiraan di sini.

Ukuran promptnya sudah diukur, 8 Agustus 2026

Dari `npm run ukur:prompt` , dan ini token yang dikirim ULANG di setiap balasan:

Bagian	Token	Catatan
System prompt	~3.400	Tetap, dikirim ulang tiap balasan
Konteks per giliran	~80	Tanggal, data kontak
Info bisnis (<code>topK</code> 5)	~1.200	5 potongan, tiap potongan sampai 900 huruf
Riwayat (10 pesan)	~600	Naik terus sepanjang obrolan
Input per balasan	~5.300	
Keluaran	~200 sampai 400	Berpikir sengaja dimatikan

System prompt itu 64 persen dari seluruh biaya input, dan sekarang dia TIDAK kena diskon. Pengukuran langsung ke API (lihat `apps/worker/src/lib/token.ts`) menemukan ambang diskonnya ada di antara 3.766 dan 6.966 token, sedangkan prompt kita 3.400. Jadi posisinya paling merugikan: sudah cukup panjang untuk mahal, belum cukup panjang untuk dapat diskon.

Catatan: `npm run ukur:prompt` dulu membandingkannya dengan ambang 1.024 dan mencetak centang hijau, jadi angkanya terbaca seolah diskonnya sudah kena. Sudah dibetulkan supaya memakai ambang yang benar-benar terukur.

Harga modelnya sudah dipastikan, 8 Agustus 2026

Dari halaman harga resmi Google (`ai.google.dev/gemini-api/docs/pricing`), paket berbayar, per 1 juta token:

Model	Input	Keluaran
Gemini 3.5 Flash (yang dipakai sekarang)	\$1,50	\$9,00
Gemini 3.5 Flash-Lite	\$0,30	\$2,50
Gemini 3.1 Flash-Lite (cadangan kita)	\$0,25	\$1,50
Gemini 3.1 Pro Preview	\$2,00	\$12,00

Yang bikin celaka bukan harga inputnya, tapi **keluarannya: \$9,00**, enam kali harga input. Perkiraan sebelumnya cuma menghitung input, dan itu keliru besar.

Jadi sekarang: Gemini 3.5 Flash bikin SEMUA paket rugi

Pakai 5.300 token input dan 300 token keluaran per balasan, kurs Rp 14.412:

Model	Ongkos per balasan	Starter Rp 66	Growth Rp 33	Pro Rp 33
Gemini 3.5 Flash	Rp 153	rugi Rp 87	rugi Rp 120	rugi Rp 120
Gemini 3.1 Flash-Lite	Rp 26	untung 61%	untung 22%	untung 22%

Satu pelanggan Growth yang memakai jatahnya penuh: $15.000 \times \text{Rp } 153 = \text{Rp } 2,29 \text{ juta ongkos}$ untuk pendapatan Rp 499.000. Rugi Rp 1,8 juta per pelanggan per bulan. Semakin banyak pelanggan, semakin cepat habis.

Paket gratis pun ikut: $51 \times \text{Rp } 153 = \text{Rp } 7.800$ per pengguna gratis per bulan.

Yang harus dikerjakan, urut

1. **GANTI MODELNYA ke `gemini-3.1-flash-lite`**. Ini yang mengubah rugi jadi untung, dan cuma satu baris di `.env` (`GEMINI_MODEL`). Enam kali lebih murah. Tugasnya menjawab dari info bisnis dan mengisi JSON, bukan penalaran bertingkat, dan token berpikir sudah lama dimatikan, jadi kelas Lite masuk akal. Buktikan dulu di halaman Coba dulu dan `npm run selftest` sebelum dipasang ke pelanggan.
2. **Jatah Pro sudah dipotong** 60.000 ke 30.000, jadi Rp 33 per balasan sama dengan Growth. Sebelumnya Rp 17, yang membuat paket termahal justru paling tipis marginnya.
3. **topK info bisnis dari 5 jadi 3**. Hemat ~480 token input per balasan.
4. **Jendela riwayat**. Sekarang sampai 60 pesan. Obrolan panjang jadi paling mahal, padahal ingatan panjangnya sudah dipegang tag CRM dan ringkasan.
5. **System prompt 3.400 token**. Dikirim ulang tiap balasan dan belum kena diskon karena ambangnya sekitar 4.000. Pindahkan inti info bisnis yang stabil ke situ supaya menyeberang ambang sekaligus mengurangi blok per giliran. Kerjakan paling akhir: sesudah pindah ke Flash-Lite, marginnya sudah aman dan ini jadi penghematan, bukan penyelamatan.

Catatan soal diskon: yang murah dan otomatis itu **implicit caching**, dan itu yang diukur di `lib/token.ts`. Angka "context caching \$0,15" di tabel harga Google itu **explicit caching**, yang ada biaya simpan \$1,00 per jam. Untuk produk dengan banyak asisten berbeda, biaya simpan per jam itu tidak masuk akal. Jangan tertukar.

Yang sudah pasti mengurangi biaya: lampiran tidak dikirim ulang ke model, token berpikir dimatikan, dan paket gratis tidak boleh membaca foto atau suara sama sekali (token gambar dan suara jauh lebih mahal daripada teks).

Biaya lain yang sudah diketahui: satu VPS untuk semuanya. Tidak ada layanan tambahan, tidak ada biaya per nomor WhatsApp, dan chat yang dimulai pelanggan tidak ditagih Meta selama dibalas dalam 24 jam.

Kebijakan uang

Jaminan 14 hari, penuh, tanpa ditanya panjang lebar, sekali per akun untuk langganan pertama. **Bulan berjalan tidak dikembalikan sebagian**, karena jatah balasannya memang sudah tersedia sebulan penuh. **Sisa jatah hangus** tiap bulan.

Dikembalikan tanpa diminta kalau: layanan mati lebih dari 24 jam berturut-turut karena kesalahan kita, kena tagih dua kali, atau akunnya dihentikan padahal tidak melanggar.

Tidak dikembalikan kalau nomornya diblokir Meta, karena itu di luar kendali kita, dan itu disebut jelas di ketentuan sebelum orang membayar.

Ajak teman

Pengajak dan yang diajak sama-sama dapat 1 bulan gratis, **cair waktu yang diajak mulai berlangganan berbayar, bukan waktu dia mendaftar**. Memberi hadiah untuk pendaftaran mengundang akun palsu.

Cara menagihnya

Midtrans Snap, terpasang 8 Agustus 2026. Paket berbayar cuma bisa dinyalakan oleh notifikasi dari Midtrans yang tanda tangannya cocok, bukan oleh tombol di dashboard. Bulan gratis dari ajak teman dipotong lebih dulu tanpa lewat Midtrans. Langganan yang habis diturunkan penjadwal di worker. Lihat peta jalan dan panduan VPS.